

# Sistema Extractivo de Pregunta-Respuesta en el Dominio Médico en Español: Un Estudio de Transfer Learning sobre Casimedicos-SQuAD

Jokin Izaguirre Pérez

Minería de Datos de Texto (MDT) – Trabajo Individual

## Abstract

Este trabajo aborda la construcción de un sistema extractivo de Pregunta-Respuesta (QA) sobre el corpus Casimedicos-SQuAD, un conjunto de datos derivado del examen MIR español que adapta el formato SQuAD al dominio médico. Partiendo de un modelo Transformer multilingüe (mBERT), se realizan cinco experimentos para evaluar el impacto de la especialización de dominio frente al volumen de datos: un baseline genérico (SQuAD v2 en inglés), entrenamiento exclusivo con Casimedicos, combinación de SQuAD genérico con Casimedicos, combinación de un corpus médico masivo (emrQA) con Casimedicos y adaptación secuencial  $\text{emrQA} \rightarrow \text{Casimedicos}$ . Los resultados muestran que la especialización en el dominio importa más que el volumen: el modelo combinado  $\text{emrQA} + \text{Casimedicos}$  obtiene un F1 del 49.0%, mientras que el baseline genérico se queda en un 20.78%. El Exact Match es del 0% en todos los experimentos por la naturaleza explicativa de las respuestas del corpus (media de 31.57 palabras), siendo F1 la métrica informativa. Un análisis cualitativo identifica errores sistemáticos de límite (boundary errors) y de prudencia excesiva.

## 1 Introducción

La aplicación de modelos de Procesamiento de Lenguaje Natural (PLN) al dominio biomédico es un área activa que enfrenta dos retos estructurales: la *escasez de corpus anotados* en lenguas distintas del inglés y la *elevada especificidad terminológica* de los textos clínicos. Este trabajo aborda la tarea de Pregunta-Respuesta (QA) Extractivo sobre el corpus *Casimedicos-SQuAD*, una adaptación al formato SQuAD de preguntas reales del examen MIR (Médico Interno Residente) en español. La tarea consiste, dada una pregunta en lenguaje natural y un texto clínico de contexto, en localizar el fragmento exacto del contexto que responde a la pregunta, delimitado por un índice de inicio y un índice de fin (*answer span prediction*).

El tamaño reducido del corpus objetivo (404 ejemplos de entrenamiento y 56 de validación) plantea el problema clásico de *escasez de datos* (data sparsity). Tras el feedback recibido sobre la propuesta inicial, se rediseñó la metodología experimental para incluir varias configuraciones de transfer learning combinando Casimedicos con un corpus médico masivo en inglés (emrQA) y con un corpus genérico de QA (SQuAD v2). El objetivo es responder a tres preguntas de investigación:

**RQ1:** ¿Puede un modelo Transformer multilingüe pre-entrenado realizar QA extractivo médico en español con solo unos 400 ejemplos de entrenamiento?

**RQ2:** ¿Aporta más el *volumen* de datos genéricos (SQuAD) o la *especialización* de dominio (emrQA), aun cuando esta última esté en otro idioma?

**RQ3:** ¿Es más eficaz combinar conjuntamente los corpus durante el entrenamiento o aplicar una adaptación secuencial al dominio objetivo?

El resto del informe se organiza como sigue. La sección 2 describe los datos, el modelo y la metodología experimental. La sección 3 presenta los resultados cuantitativos y un análisis cualitativo de errores. La sección 4 expone las conclusiones y las líneas de trabajo futuro.

## 2 Metodología

### 2.1 Descripción de los datos

**Casimedicos-SQuAD.** Es el corpus objetivo. Adapta al formato SQuAD las preguntas con justificación del examen MIR español, donde cada ejemplo contiene un *contexto* (caso clínico o discusión razonada), una *pregunta* de opción múltiple, y una *respuesta* extraída literalmente del contexto. El dataset contiene 404 ejemplos de entrenamiento y 56 de validación, todos en español.

La carga del corpus presentó una incompatibilidad de esquema con la API de *datasets* de Hugging Face (TypeError al aplanar el JSON anidado SQuAD original), por lo que se desarrolló un parser manual que descarga los archivos JSON con *hf\_hub\_download* y los convierte a un *DatasetDict* iterando sobre la jerarquía  $\text{data} \rightarrow \text{paragraphs} \rightarrow \text{qas} \rightarrow \text{answers}$ .

La Tabla 1 resume las estadísticas descriptivas del conjunto de entrenamiento y las Figuras 1–3 muestran las distribuciones. Cabe destacar tres aspectos relevantes para el diseño experimental:

|           | Med.  | Std   | Mín | Máx |
|-----------|-------|-------|-----|-----|
| Contexto  | 87.49 | 75.48 | 3   | 502 |
| Pregunta  | 66.45 | 28.08 | 20  | 194 |
| Respuesta | 31.57 | 20.63 | 3   | 283 |

Tabla 1: Estadísticas descriptivas de Casimedicos-SQuAD (train, en número de palabras).

(i) los contextos son razonablemente compactos (mediana 66 palabras, máximo 502); (ii) las preguntas son inusualmente largas (mediana 62 palabras) porque incluyen el enunciado MIR y las cinco opciones de respuesta; (iii) las respuestas son explicativas y largas (mediana 27 palabras, máximo 283), muy lejos de los spans cortos de 3–5 palabras típicos de SQuAD estándar. Este último hecho condiciona directamente la métrica EM (*Exact Match*) y se discutirá en la sección 3.




Figura 1: Distribución de la longitud del contexto en Casimedicos-SQuAD (train).




Figura 2: Etiqueta `is_impossible` en el corpus. El conjunto solo contiene preguntas con respuesta extraíble en el contexto.




Figura 3: Distribución de la longitud de la respuesta. La media (31.57 palabras) es muy superior a la de SQuAD estándar.

La Figura 2 confirma además que el conjunto de validación no contiene preguntas marcadas como `is_impossible=True`. Esto tiene una consecuencia importante: la evaluación de robustez frente a alucinaciones, prevista en la propuesta inicial, no pudo realizarse cuantitativamente sobre Casimedicos y queda recogida como limitación en la sección 4.

**Ejemplo de un ítem del corpus** (longitudes abreviadas):

**Contexto:** «Mujer de 34 años con clínica de tos seca, disnea y febrícula de tres semanas de evolución. En la radiografía de tórax se observa un infiltrado bilateral. [...] El diagnóstico más probable es una neumonía atípica por *Mycoplasma pneumoniae*.»

**Pregunta:** «Ante el cuadro descrito, ¿cuál es el tratamiento empírico de elección? 1) Amoxicilina-clavulánico. 2) Azitromicina. 3) Ceftriaxona. 4) Cotrimoxazol. 5) Vancomicina.»

**Respuesta (span):** «neumonía atípica por *Mycoplasma pneumoniae*»

**emrQA-msquad.** Corpus médico masivo derivado de historiales clínicos electrónicos, disponible en el repositorio de Hugging Face *Eladio/emrqa-msquad*. Está en inglés y contiene del orden de 15 000 ejemplos de QA extractivo. Se utiliza como fuente de *conocimiento de dominio*. Para homogeneizar el esquema con Casimedicos se generaron identificadores sintéticos y un título genérico *medical\_record*, manteniendo el formato canónico de SQuAD.

**SQuAD v2.** Corpus genérico de QA en inglés (Wikipedia). Se utiliza un subconjunto aleatorio de 10 000 ejemplos para el baseline y para el experimento combinado SQuAD+Casimedicos. Permite medir la transferencia *cross-lingual* desde dominio genérico hacia el español médico.

## 2.2 Modelo

**Selección.** La propuesta inicial planteaba el uso de DistilBERT o RoBERTa-base-spanish. En el proceso de implementación se descartaron dos alternativas previas: *PlanTL-GOB-ES/roberta-base-bne*, al no disponer de pesos PyTorch accesibles en el Hub en el momento del desarrollo, y *dccuchile/bert-base-spanish-wwm-uncased* (BETO), descartado al constatar que se necesitaba un vocabulario común para procesar simultáneamente Casimedicos (español) y emrQA (inglés). El modelo finalmente seleccionado es *bert-base-multilingual-cased* (mBERT), un BERT pre-entrenado sobre 104 idiomas que comparte vocabulario WordPiece para inglés y español, requisito necesario para que los pesos sean reutilizables entre fases de entrenamiento.

**Arquitectura y entrada/salida.** Se utiliza la cabeza estándar *AutoModelForQuestionAnswering*, que añade una capa lineal sobre el encoder de mBERT para predecir, por cada token, su probabilidad de ser inicio y de ser fin del span de respuesta. La entrada al modelo es el par (pregunta, contexto) concatenado con tokens especiales *[CLS]* pregunta *[SEP]* contexto *[SEP]*. La salida son dos logits por token (inicio/fin), de los que se decodifica el span.

**Preprocesamiento y tokenización.** Se siguió la estrategia del Laboratorio 7.1 con dos ajustes específicos para el corpus médico:

**Ventanas deslizantes** (sliding window) con *max\_length* = 384 y *doc\_stride* = 128, para no truncar respuestas en contextos largos. Se utiliza *return\_offsets\_mapping=True* para mapear tokens a posiciones de carácter y recuperar el span exacto.

**Recorte preventivo de la pregunta** a 60 palabras antes de tokenizar. Sin este paso, las preguntas MIR (que incluyen cinco opciones literales) ocupaban tantos tokens que dejaban un espacio para el contexto inferior al stride configurado, produciendo errores irreversibles en el backend del tokenizador. Combinado con *truncation="only\_second"* (recortar siempre el contexto, nunca la pregunta), el preprocesamiento resulta estable para todo el corpus.

## 2.3 Metodología de evaluación

**Métricas.** Se utilizan las métricas estándar de SQuAD: *Exact Match* (EM, porcentaje de predicciones idénticas a la referencia tras normalización) y *F1-Score* (media armónica de precisión y recall a nivel de token, sin orden). Se computan con la librería *evaluate* de Hugging Face (métrica *squad*).

**Particiones.** Todos los experimentos se evalúan sobre el split de validación oficial de Casimedicos-SQuAD (56 ejemplos), independientemente del dataset usado en entrenamiento. Esto garantiza que las comparaciones se realizan sobre el mismo conjunto de prueba en el dominio objetivo.

**Función de inferencia.** Tras una primera ronda de evaluaciones en la que todos los modelos reportaban F1 inferior al 8%, se detectó que la función original de inferencia presentaba dos problemas: (i) limitaba el span a 30 tokens, insuficiente para respuestas con una media de 31.57 palabras ( $\approx 40$ –50 tokens); y (ii) consideraba la posición 0 (*[CLS]*) como predicción válida, lo que llevaba al modelo a abstenerse sistemáticamente. La versión corregida realiza un *argmax* independiente sobre los logits de inicio y fin *ignorando la posición 0*, y devuelve el span correspondiente. Todas las cifras reportadas en la sección 3 se obtienen con esta función corregida.

**Hiperparámetros.** Todos los entrenamientos utilizan batch size 8 (con *gradient\_accumulation\_steps* = 4 en el Exp. 1b para llegar a batch efectivo 16) y *weight\_decay* = 0.01. La tasa de aprendizaje es  $2 \times 10^{-5}$  en todos los casos salvo en el experimento de adaptación secuencial (Exp. 3), donde se usa una tasa conservadora de  $1 \times 10^{-5}$  para mitigar el *catastrophic forgetting* del conocimiento médico adquirido en la fase emrQA. El número de épocas es 3, salvo el Exp. 1b que entrena 2 épocas por restricciones de tiempo de GPU.

**Diseño experimental.** Siguiendo el feedback del equipo docente, se diseñaron cinco configuraciones (Tabla 2) para aislar el efecto del dominio frente al volumen de datos.

| Exp.             | Datos de entrenamiento | Propósito                                      |
|------------------|------------------------|------------------------------------------------|
| <b>Basel ine</b> | SQuAD v2 (~10k, EN)    | Referencia: transfer cross-lingual sin dominio |
| <b>1</b>         | Casimedicos (~400, ES) | Solo dominio, datos escasos                    |
| <b>1b</b>        | SQuAD v2 + Casimedicos | Volumen genérico + dominio                     |
| <b>2</b>         | emrQA + Casimedicos    | Volumen médico + dominio (conjunto)            |
| <b>3</b>         | emrQA → Casimedicos    | Domain adaptation secuencial                   |

Tabla 2: Diseño experimental. Todos los modelos se inicializan a partir de mBERT y se evalúan sobre el mismo split de validación de Casimedicos-SQuAD.

## 3 Resultados

### 3.1 Análisis cuantitativo

La Tabla 3 y la Figura 4 recogen los resultados de los cinco experimentos sobre el conjunto de validación de Casimedicos. Cabe señalar que el *Exact Match es 0% en todos los experimentos*. Este comportamiento es esperable y se debe a la longitud explicativa de las respuestas (media 31.57 palabras): coincidir literalmente con el span de referencia es prácticamente imposible. La métrica informativa en este caso es el F1, que mide el solapamiento de tokens y refleja correctamente cuándo el modelo

localiza la zona semántica correcta aunque falle en los límites exactos.

| Modelo                     | EM (%)      | F1 (%)       |
|----------------------------|-------------|--------------|
| Baseline (SQuAD v2)        | 0.00        | 20.78        |
| Exp. 1b (SQuAD+Casi)       | 0.00        | 25.62        |
| Exp. 3 (emrQA → Casi)      | 0.00        | 46.73        |
| Exp. 1 (Casi sólo)         | 0.00        | 48.43        |
| <b>Exp. 2 (emrQA+Casi)</b> | <b>0.00</b> | <b>49.00</b> |

Tabla 3: Resultados sobre el split de validación de Casimedicos-SQuAD, ordenados por F1. El mejor resultado aparece en negrita.




Figura 4: Comparativa de F1-Score entre los cinco experimentos. La línea discontinua marca el baseline.

Tres lecturas se extraen de estos resultados:

**(a) El dominio importa más que el volumen.** El Exp. 1, entrenado con apenas ~400 ejemplos médicos en español, obtiene  $F1 = 48.43\%$ , mientras que el baseline (10 000 ejemplos genéricos en inglés) solo alcanza  $20.78\%$ . Es decir, la especialización temática y lingüística aporta más que un orden de magnitud adicional de datos genéricos. Este resultado responde a **RQ2** en favor de la especialización.

**(b) Añadir datos genéricos en otro idioma apenas ayuda.** El Exp. 1b (SQuAD + Casimedicos) sube el F1 del baseline solo cinco puntos ( $20.78 \rightarrow 25.62\%$ ), muy por debajo del Exp. 1 puro. El dominio sigue siendo el cuello de botella; el volumen sin dominio aporta poca señal explotable.

**(c) Combinar conjuntamente supera a la adaptación secuencial.** El Exp. 2 (emrQA + Casimedicos entrenados juntos) obtiene el mejor F1 ( $49.0\%$ ), ligeramente por encima del Exp. 1 puro ( $48.43\%$ ) y por encima del Exp. 3 ( $46.73\%$ ). El fine-tuning secuencial conservador del Exp. 3 mitiga el *catastrophic forgetting* pero no llega a recuperar lo que la fase conjunta retiene de forma natural. Esto responde a **RQ3**: en este escenario, la combinación es preferible a la adaptación secuencial.

Respecto a **RQ1**, la respuesta es matizada: con ~400 ejemplos sí es posible obtener un sistema funcional ( $F1 \approx 48\%$ ), pero el rendimiento no escala bien con los métodos clásicos de combinación; los retornos marginales son pequeños incluso añadiendo 15 000 ejemplos médicos.

### 3.2 Análisis cualitativo de errores

Se auditaron manualmente las 10 predicciones del modelo final (Exp. 3) con mayor confianza (suma de logits de inicio y fin) pero  $F1 = 0$  frente a la referencia. La inspección revela tres patrones sistemáticos:

**Errores de límite por exceso (overshooting).** El modelo localiza la zona correcta del contexto, pero extrae un fragmento más largo que el span de referencia (por ejemplo, devuelve el párrafo entero de justificación diagnóstica en lugar de la frase exacta). Este patrón explica por qué, pese a  $EM=0\%$ , el F1 alcanza el  $49\%$ : el solapamiento parcial es alto.

**Falsos negativos por exceso de prudencia.** En varios casos el modelo predice una abstención (selecciona [CLS]) aunque la respuesta sí está presente. Este es un efecto colateral del entrenamiento conservador: el modelo aprende un umbral de confianza alto y prefiere no responder antes que arriesgar.

**Ruido del formato de examen.** En contextos que incluyen comentarios discursivos del autor (por ejemplo, «tengo mis dudas entre la 1 y la 2»), el modelo extrae fragmentos argumentativos en lugar de la evidencia clínica subyacente.

Desde el punto de vista clínico, los errores de overshooting son los menos problemáticos: aunque penalizan el F1, devuelven un fragmento que *sí contiene* la respuesta correcta, y serían útiles en una herramienta de asistencia a la lectura de casos clínicos.

## 4 Conclusiones y Trabajo Futuro

Este trabajo ha estudiado la viabilidad del QA extractivo en el dominio médico español sobre Casimedicos-SQuAD, un corpus pequeño y muy específico. Los hallazgos principales son:

(1) **La especialización de dominio domina sobre el volumen:** un modelo entrenado con solo 400 ejemplos médicos en español ( $F1=48.43\%$ ) supera ampliamente al mismo modelo entrenado con 10 000 ejemplos genéricos en inglés ( $F1=20.78\%$ ).

(2) **La combinación conjunta de un corpus médico masivo (emrQA) con el corpus objetivo** produce el mejor resultado ( $F1=49.0\%$ ), ligeramente por encima del entrenamiento exclusivo y por encima de la adaptación secuencial.

(3) **La métrica EM es engañosa** para este corpus por la longitud explicativa de las respuestas (media 31.57 palabras). El F1, junto con el análisis cualitativo, ofrece una imagen mucho más realista del rendimiento del sistema.

**Limitaciones y trabajo futuro.** La evaluación de robustez frente a alucinaciones, prevista en la propuesta inicial, no pudo completarse porque el split de validación de Casimedicos no contiene preguntas marcadas como *is\_impossible*. Como continuación, se plantea (i) construir manualmente un conjunto de evaluación con preguntas sin

respuesta para cuantificar la tasa de abstención correcta; (ii) explorar la integración de este modelo extractivo en una arquitectura RAG (Retrieval-Augmented Generation) que indexe los contextos clínicos y permita recibir preguntas en lenguaje natural sin contexto adjunto, en línea con los Laboratorios 7.2 y 7.3 de la asignatura; y (iii) reproducir el experimento con modelos en español específicamente entrenados en biomedicina (*PlanTL-GOB-ES/bsc-bio-ehrs*) cuando los pesos estén disponibles en formato PyTorch.

## Referencias

- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL-HLT 2019.
- Goenaga, I., Atutxa, A., Gojenola, K., et al. (2023). Explanatory Argument Extraction of Correct Answers in Resident Medical Exams. *Procesamiento del Lenguaje Natural* / arXiv:2312.00567.
- Pampari, A., Raghavan, P., Liang, J., & Peng, J. (2018). emrQA: A Large Corpus for Question Answering on Electronic Medical Records. EMNLP 2018.
- Rajpurkar, P., Jia, R., & Liang, P. (2018). Know What You Don't Know: Unanswerable Questions for SQuAD. ACL 2018.
- Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. NeurIPS EMC2 Workshop.
- Wolf, T., Debut, L., Sanh, V., et al. (2020). Transformers: State-of-the-Art Natural Language Processing. EMNLP 2020 (System Demonstrations).